


1. Basic.



$$\sin \beta = \frac{a}{c}$$
$$\cos \beta = \frac{b}{c}$$
$$\tan = \frac{a}{b}$$

cosine Similarity

$$\cos \theta = \frac{a \cdot b}{\|a\| \cdot \|b\|}$$

$$a \cdot b = \|a\| \|b\| \cdot \cos \theta$$

特征向量与特征值. 方阵 A , 非零向量 x

$$Ax = \lambda x$$

$$(A - \lambda I)x = 0.$$

$$\det(A - \lambda I) = 0$$

若 $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$

$$\begin{vmatrix} 2 & 1 \\ 1 & 2 \end{vmatrix} - \lambda \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} = 0.$$

$$\begin{vmatrix} 2-\lambda & 1 \\ 1 & 2-\lambda \end{vmatrix} = 0$$

$$(2-\lambda)^2 - 1 = 0$$

$$(2-\lambda)^2 = 1$$

$$2-\lambda = \pm 1$$

$$\lambda = 1 \text{ or } 3$$

$$\lambda = 3 \quad X_1 = \left(\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} - \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix} \right) X = 0$$

$$\begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\begin{cases} -x_1 + x_2 = 0 \\ x_1 - x_2 = 0 \end{cases}$$

$$x_1 = x_2$$

$$\text{Let } x_1 = 1, x_2 = 1$$

$$\lambda = 1 \quad \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$x_1 + x_2 = 0$$

$$x_1 = 1 \quad x_2 = -1$$

Graph

pagerank.

row-adjacency matrix $\begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$

↓

column-stochastic.

$$\begin{bmatrix} 0 & \frac{1}{2} & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 & 1 \\ 0 & 0 & \frac{1}{2} & 0 \end{bmatrix}$$

{ link in
link out.

$$r = M \cdot r.$$

$$\begin{bmatrix} 0 & \frac{1}{2} & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 & 1 \\ 0 & 0 & \frac{1}{2} & 0 \end{bmatrix} \begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix} = \begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix}$$

$$\begin{cases} \frac{1}{2}r_2 = r_1 \\ \frac{1}{2}r_1 + \frac{1}{2}r_3 = r_2 \\ \frac{1}{2}r_1 + \frac{1}{2}r_2 + r_4 = r_3 \\ \frac{1}{2}r_3 = r_4 \end{cases}$$

$$r_1 + r_2 + r_3 + r_4 = 1$$

$$r_1 + r_2 = 2(r_3 + r_4)$$

$$2r_3 - 2r_4 + r_3 + r_4 = 1$$

$$3r_3 - r_4 = 1$$

$$\underline{3r_3 = 1 + r_4}$$

$$3r_3 - 1 = \frac{1}{2}r_3$$

$$\frac{5}{2} r_3 = 1$$

$$r_3 = \frac{2}{5}$$

$$r_1 = \frac{2}{15}$$

$$r_2 = \frac{4}{15}$$

$$r_4 = \frac{1}{5}$$

Link Spam.

① creat a lot of support page.
put link in public website

②. linked each other.
point out to target page.

③ linked each other →
high score → target page
more support page ↑


higher score of target page

Edge Betweenness

Brandes' algorithm.


Top down

每个节点从 root node 开始的最短路径数



Bottom-up.

每个节点有初始 1 credit



$$Eb[a] = \frac{3}{2}$$

按权重分配

四个节点分别作 root node,

$$E_b(a)_{\text{final}} = \frac{\sum_4 E_b(a)}{2}$$

Spectral Clustering.

$$W = \begin{bmatrix} 1 & 0.2 & 0 & 0 \\ 0.2 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0.5 \\ 0 & 0 & 0.5 & 1 \end{bmatrix}$$

权重 matrix W , 代表节点之间的相似程度.

度 matrix D , W 每行或每列之和.

$$D = \begin{bmatrix} 1.2 & & & \\ & 1.2 & & \\ & & 1.5 & \\ & & & 1.5 \end{bmatrix}$$

拉普拉斯矩阵 $L = D - W$.

$$L = \begin{bmatrix} 0.2 & -0.2 & 0 & 0 \\ -0.2 & 0.2 & 0 & 0 \\ 0 & 0 & 0.5 & -0.5 \\ 0 & 0 & -0.5 & 0.5 \end{bmatrix}$$

$$2. \quad |\lambda I - L| = 0. \quad I = \begin{bmatrix} 1 & & & \\ & 1 & & \\ & & 1 & \\ & & & 1 \end{bmatrix}$$

$$\left| \begin{bmatrix} \lambda & & & \\ & \lambda & & \\ & & \lambda & \\ & & & \lambda \end{bmatrix} - \begin{bmatrix} 0.2 & -0.2 & 0 & 0 \\ -0.2 & 0.2 & 0 & 0 \\ 0 & 0 & 0.5 & -0.5 \\ 0 & 0 & -0.5 & 0.5 \end{bmatrix} \right| = 0.$$

$$\begin{vmatrix} \lambda - 0.2 & 0.2 & 0 & 0 \\ 0.2 & \lambda - 0.2 & 0 & 0 \\ 0 & 0 & \lambda - 0.5 & 0.5 \\ 0 & 0 & 0.5 & \lambda - 0.5 \end{vmatrix} = 0$$

$$\begin{vmatrix} \begin{bmatrix} \lambda - 0.2 & 0.2 \\ 0.2 & \lambda - 0.2 \end{bmatrix} \cdot \begin{bmatrix} \lambda - 0.5 & 0.5 \\ 0.5 & \lambda - 0.5 \end{bmatrix} \end{vmatrix} = 0$$

$$\left(\begin{bmatrix} (\lambda - 0.2)^2 - 0.04 \end{bmatrix} \cdot \begin{bmatrix} (\lambda - 0.5)^2 - 0.25 \end{bmatrix} \right) = 0$$

$$\lambda - 0.2 = \pm 0.2$$

$$\lambda = 0 \text{ or } 0.4$$

$$\lambda - 0.5 = \pm 0.5$$

$$\lambda = 1 \text{ or } 0$$

$$\lambda_1 = 0 \quad \lambda_2 = 0.4 \quad \lambda_3 = 0.1 \quad \lambda_4 = 1$$

用第二小的特征值

$$0, 0.1, 0.4, 1$$

对应的特征向量

eigenvector

$$[\lambda I - L] X = 0$$

$$[-L] X = 0$$

$$\begin{bmatrix} 0.2 & -0.2 & 0 & 0 \\ -0.2 & 0.2 & 0 & 0 \\ 0 & 0 & 0.5 & -0.5 \\ 0 & 0 & -0.5 & 0.5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

$$0.2x_1 - 0.2x_2 = 0$$

$$-0.2x_1 + 0.2x_2 = 0$$

$$0.5x_3 - 0.5x_4 = 0$$

$$-0.5x_3 + 0.5x_4 = 0$$

$$\begin{cases} x_1 = x_2 \\ x_3 = x_4 \end{cases}$$

node 1, node 2.

node 3 node 4

4. Influence Spread.

列举出所有可能情况.

计算这种情况出现的概率

$$\sum \left(\text{概率} \times \text{从开始节点开始能影响的节点数} \right)$$

LSH.

1. minHash Signature generation.

存在填1. 不存在填0.

ID		S_1	S_2	S_3	S_4	π
0	a	1	1	0	0	3
1	b	1	1	0	0	0
2	c	0	0	1	1	5
3	d	0	1	1	0	2
4	e	1	0	1	1	4
5	f	0	0	0	1	1

给定 π . 根据 π 的顺序, 填第一个1出现的 π 的数

S_1 S_2 S_3 S_4
 0 0 2 1

IP 是用来生成 $h(x)$ 的输入,

生成元用的.

生成的 permutations 不能有重复

估计的 Jaccard Similarities


用签名比例 用签名 的相似度, 00 也算
估计 Jaccard similarity.

真正 的 JS 用矩阵 $\frac{\text{交集}}{\text{并集}} \rightarrow 00$ 不算

more efficient, but not
always accurate.

Similarity / Distance measure.

1. Jaccard Similarity.



2. Cosine Similarity.

根据存在 变成向量

A (1, 1, 1, 1, 0, 0)

B (1, 1, 0, 1, 1, 1)

S_1 S_2 - - - - -

$$|A| = \sqrt{4} = 2$$

$$|B| = \sqrt{5}$$

$$\text{CosSim} = \frac{A \cdot B}{|A| \cdot |B|}$$

$$\cos_{xy} = \frac{|+|+|}{2 \cdot \sqrt{5}} = \frac{3}{2\sqrt{5}} = \frac{3}{10\sqrt{5}}$$

Sim Hash

给定的随机向量与文档向量做点积

若大于0, 为1, 小于0, 为0.

几个随机向量 r , Sim Hash 几个.

$$hr_1(A) = 1.4 \rightarrow 1$$

$$hr_2(A) = 1.1 \rightarrow 1$$

$$hr_3(A) = 1.1 \rightarrow 1.$$

Sim Hash signature for $A = [1, 1, 1]$

Parameters Tuning for effective LSH

$d_1 = 0.7 \rightarrow$ 大于 0.7, 应判断为相似

$d_2 = 0.3 \rightarrow$ 小于 0.3 应判断为

$p(s)$ 是未被认为相似 不相似.

false negative. $\rightarrow$ 本应相似的, 判为了不相似
0.7 阈值
 $1 - p(s)$

false positive. $\rightarrow$ 本应不相似, 判为了相似
(0.3)
 $p(s)$

Data Streaming

Sampling and Bloom Filter

Reservoir sampling.

① put s element into reservoir.

② for each subsequent item m ($m > s$)

have $\frac{s}{m}$ possibility to replace
random one element of reservoir

Bloom filter.


① create a m length vector S
and all number set 0.

② select k hash function.

insert element

③. hash element into S . if
exist, set 1

④. if $\text{hash}(a) = 0$, a not
exist
 $\text{hash}(a) = 1$, a may
exist.



$\uparrow$ FP rate $\downarrow \uparrow$

Misra-Gries Algorithm.

插入表, 若没满, 加入表.

若存在, $counter + 1$

若不存在且满了, 所有 $counter - 1$

$counter = 0$, 删去

k size table,

m element

n' is item ^{left} number 要算计数器

$n =$ decrease step number

$$m = n' + n(k+1)$$

↘ 每次是减了 $(k+1)$

$$n = \frac{m - n'}{k+1}$$

Count Min Sketch Algorithm.

① 算对应哈希值

多个哈希函数

每个插入对应的 bucket t

查询时, 选最小的哈希 counter 为结果

最后的结果 matrix 为 counter matrix

预估...

如何查值? 若查 $x=1$.

$h_1(1) = 2$, 找到 counter matrix 的 第二列
对应哈希第二个槽

$h_2(1) = 1$

对应哈希第一个槽,

第一列

找到最小的, 取 $\min$.

真实直接数, 比较.

count sketch Algorithm.

① 算哈希.

② counter Matrix.

有正有负, 看具体情况算

③ 找到对应的槽的计算求以 $S_i(x)$ 的值, 再取中位数作为预测结果.

④ 对比.

collaborative Filtering.

先把评分矩阵转换, 缺失当成0

$$\textcircled{1} \text{ Cos Similarity} = \frac{V_1 \cdot V_2}{\|V_1\| \|V_2\|}$$

↙
平方和再开方

② pearson correlation coefficient

① 先算这个人的平均评分

对评分矩阵的对应的人都减去平均

再 cos 相似度:

只有两人都有的评分。

预测 $\frac{A\text{评分} \cdot A\text{相似度} + B\text{评分} \cdot B\text{相似度}}{|A\text{相似度}| + |B\text{相似度}|}$

无偏差 $\uparrow$

有偏见。

bias global $\rightarrow$ bg

use based CF

$$\frac{w_{21}(r_{21} - b_{21}) + w_{31}(r_{31} - b_{31})}{|w_{21}| + |w_{31}|}$$

A的 B的

$$r_{41} = bg + r_4^v + r_i^i +$$

相似度乘(评分减偏)
|相似度|之和

$$r_{ui} = b_{u,i} +$$

三种偏差

偏差模型

$$b_{u,i} = b_g + \underbrace{b_i}_{\substack{\text{物品} \\ \text{偏差} \\ \text{物品平均} \\ - b_g}} + \underbrace{b_u}_{\substack{\text{用户偏差} \\ \text{用户平均} - b_g}}$$

评价

evaluation of RS

均方误差

$$\text{MSE} = \frac{\sum (\text{预测} - \text{真实})^2}{\text{个数}}$$

$$\text{RMSE} = \sqrt{\text{MSE}}$$

MSE 越低越好.

Top-N Precision@1

Recall@1

看推荐的用户喜不喜欢

转化评分或是否喜欢

标准看题

$$\text{Precision} = \frac{\text{预测是喜欢的}^{TP}}{\text{预测喜欢的}^{(真, 假)} TP + FP}$$

$$\text{Recall} = \frac{\text{命中}^{TP} \text{的喜欢的}}{\text{真喜欢的所有} TP + FN}$$

Modularity

总边数 m 每个点的度 k_i

e_{ii} : 每个社区的内部边条数
 m

a_i : 社区总边数和
 $\geq m$

$$Q = \sum (e_{ii} - a_i^2)$$

5个社区

$$m = 5$$

$$k_1 = 1$$

$$k_2 = 3$$

$$k_3 = 2$$

$$k_4 = 2$$

$$k_5 = 2$$

$$\textcircled{e_{ii}} = \frac{0}{3}$$

$$e = \frac{0}{3}$$

$$1 = \frac{0}{3}$$

$$1 = \frac{0}{3}$$

$$a_i = \frac{1}{2m} = \frac{1}{10}$$

$$= \frac{3}{2m} = \frac{3}{10}$$

$$\frac{2}{2m} = \frac{2}{10}$$

$$\frac{2}{2m} = \frac{2}{10}$$

$$\frac{2}{2m} = \frac{2}{10}$$

$$\sum \left(0 - \left(\frac{1}{10} \right)^2 + \dots \right)$$

$$= -0.22.$$

我脑子已经转不动了 你直接给我一个例子 让我直接记住做题的步骤

已思考 38s >

没问题！给你一个直接照抄就能算的示例 + 固定步骤。

记住一句话： $Q = \sum(\text{社区内实际边比例}) - \sum(\text{随机期望边比例})$ ，用下面 5 步就能落地。

固定步骤（背这个就够用）

1. 数边：记总边数 m ；每个点的度 k_i 。
2. 选划分：把节点分到若干社区 $C_1, C_2, \dots$ 。
3. 算 e_{ii} ：社区 C_i 的内部边条数 / m 。
4. 算 a_i ：社区 C_i 的度数之和 / $2m$ 。（更快！）
5. 求模块度：

$$Q = \sum_i (e_{ii} - a_i^2)$$

（这是最容易手算的形式。）